Data Warehouse Modernization: Reproiectarea unei arhitecturi clasice de Data Warehouse într-o arhitectură modernă

Oct 25, 2026 · | Olaru David | Master : Informatica Economica | Anul I | Grupa : 1123

1. Introducere

Un Data Warehouse (DW) clasic, alimentat noaptea printr-un proces ETL, ajunge repede la limită când o companie cere rapoarte rapide, date proaspete și întrebări noi în fiecare săptămână.

Problema de business. Compania studiată este o rețea de retail cu 10 magazine fizice și 2 canale online (magazinul online și aplicația mobilă). Ea vinde electronice, electrocasnice, fashion și articole pentru casă și grădină. Datele ajung la analiști într-un singur fișier mare, denormalizat, extras din sistemul operațional (varianta „legacy"). Orice întrebare nouă înseamnă fie modificarea acelui fișier, fie un raport construit manual.

Întrebarea de cercetare. Cum poate fi reproiectat un Data Warehouse clasic într-o arhitectură modernă și ce câștigă compania din asta, în privința calității modelului, a întreținerii și a scalării?

Obiectivele studiului:

- descrierea arhitecturii clasice de DW și a limitelor ei;
- prezentarea arhitecturii moderne: cloud, ELT, lakehouse cu straturi bronze/silver/gold și BI self-service;
- demonstrarea practică, în Power BI, a trecerii de la un tabel plat la o schemă stea, cu aceleași rezultate de business;
- formularea de concluzii proprii, inclusiv despre limitele demonstrației.

Datele folosite. Setul de date este sintetic, generat special pentru acest studiu de caz: 43.208 linii de vânzări din perioada 2023-2025, 65 de produse, 1.500 de clienți și 12 puncte de vânzare. Cifrele din referat ilustrează arhitectura, nu piața reală.

2. Arhitectura clasică de Data Warehouse

Arhitectura clasică mută datele într-un singur sens, în loturi (batch), de la sistemele operaționale la rapoarte, iar fiecare etapă este rigidă și dependentă de cea dinainte.

Fluxul tipic

1. **Surse operaționale:** ERP, sistemul de casă din magazine, platforma online, fișiere exportate.
2. **ETL (Extract, Transform, Load):** un proces programat, de obicei noaptea, care extrage datele, le curăță și le transformă *înainte* de încărcare.
3. **Zona de staging:** tabele intermediare în care datele sunt aduse și verificate.
4. **Data Warehouse central:** baza de date relațională (de exemplu SQL Server on-premises), cu date integrate și istorice. În abordarea lui Inmon, acesta este modelul normalizat al întregii companii; în cea a lui Kimball, el este format din data marts dimensionale (scheme stea).

5. **Data marts și rapoarte:** subseturi pe domenii (vânzări, stocuri) din care se construiesc rapoartele.

Limitele arhitecturii clasice

- **Latență mare:** datele sunt cunoscute abia a doua zi; nu se poate reacționa la o campanie în timpul ei.
- **Scalare costisitoare:** creșterea volumului cere hardware nou, cumpărat pentru vârful de sarcină (de exemplu noiembrie-decembrie) și nefolosit restul anului.
- **Rigiditate:** transformările se fac înainte de încărcare, deci o coloană nouă sau o regulă schimbată înseamnă modificarea ETL-ului și reîncărcarea datelor.
- **Date structurate doar:** jurnalele, datele din aplicații sau fișierele semistructurate intră greu într-un model relațional fix.
- **Dependența de echipa IT:** analiștii cer rapoarte, nu își fac singuri analiza (BI centralizat).

În cazul nostru, varianta „legacy" este forma extremă a acestor limite: un singur tabel plat, în care numele produsului, al clientului și al magazinului se repetă pe zeci de mii de rânduri.

3. Arhitectura modernă

Arhitectura modernă păstrează ideea unui loc unic pentru date de încredere, dar o mută în cloud, aduce datele brute întâi și le transformă pe urmă (ELT), iar analiza devine accesibilă și utilizatorilor de business.

Componentele principale

- **Cloud și separarea stocării de calcul:** stocarea ieftină (obiecte, fișiere) crește independent de puterea de calcul, care se pornește doar când e nevoie și se plătește la consum.
- **ELT în loc de ETL:** datele se încarcă mai întâi aproape neschimbate, iar transformările rulează în platformă, deci pot fi refăcute oricând din datele brute, fără o nouă extragere din surse.
- **Lakehouse:** combină flexibilitatea unui data lake (orice tip de date, cost mic) cu fiabilitatea unui data warehouse (tabele, tranzacții, interogări SQL), pe formate deschise.
- **Straturile bronze, silver, gold (medallion):** *bronze* păstrează datele brute exact cum au venit; *silver* le curăță și le standardizează; *gold* conține modelele gata pentru analiză, de exemplu schema stea pentru vânzări.
- **Date aproape de timp real:** pe lângă încărcarea în loturi, evenimentele (vânzări online, plăți) pot fi ingerate continuu.
- **BI self-service și guvernanță:** analiștii își construiesc singuri rapoartele pe un model semantic comun (de exemplu în Power BI), iar un catalog de date urmărește proveniența, calitatea și accesul.

Unde se așază prototipul nostru. Stratul *gold* al unui lakehouse este, de fapt, un model dimensional: un tabel de fapte (vânzările) înconjurat de dimensiuni (timp, produs, client, magazin). Prototipul din Power BI construiește exact acest strat gold și arată ce primește analistul când datele sunt modelate corect, indiferent dacă platforma de dedesubt este on-premises sau în cloud.

4. Comparație: clasic vs. modern

Diferența principală nu este tehnologia în sine, ci ordinea operațiilor și felul în care se plătește și se schimbă sistemul.

Criteriu	Arhitectura clasică	Arhitectura modernă
Procesare	ETL: transformare înainte de încărcare	ELT: încărcare întâi, transformare în platformă
Latență	Încărcări în loturi, de obicei nocturne	Loturi și flux continuu, aproape de timp real
Scalare	Verticală, prin hardware nou	Orizontală, la cerere, stocare separată de calcul
Cost	Investiție inițială mare (CAPEX), capacitate dimensionată pentru vârf	Plată la consum (OPEX), capacitate ajustată în sezon
Tipuri de date	Mai ales structurate	Structurate, semistructurate și nestructurate
Flexibilitate la schimbare	Mică: modifici ETL-ul și reîncarci	Mare: refaci transformările din datele brute păstrate
Guvernanță	Reguli în procese și documente, adesea manuale	Catalog de date, urmărirea proveniencei, acces pe roluri
Acces pentru analiști	Centralizat prin IT	Self-service pe un model semantic comun

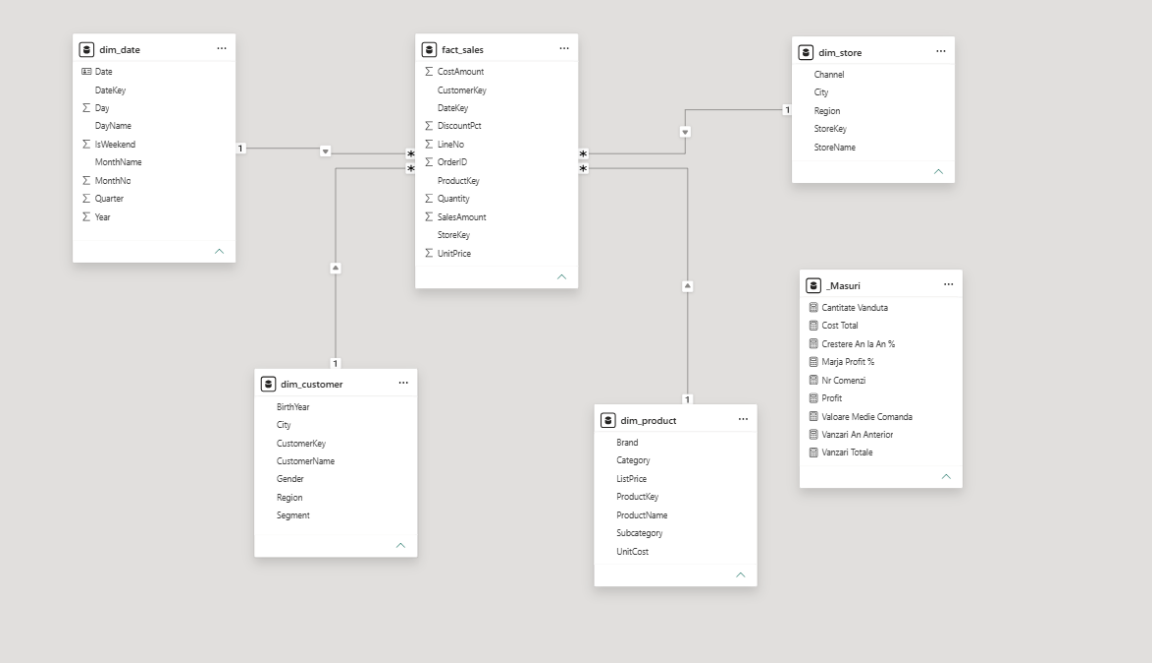
Arhitectura modernă nu este însă gratuită: cere competențe noi (cloud, ingineria datelor), un control atent al costurilor la consum și o disciplină de guvernanță, altfel lacul de date devine „mlaștină de date". Pentru volume mici și cerințe stabile, un DW clasic bine proiectat rămâne o soluție rezonabilă.

5. Componenta practică: prototip în Power BI

Prototipul transformă extractul „legacy" într-un model dimensional și îl folosește pentru un dashboard cu trei pagini, adică exact ce ar livra stratul *gold* al unui lakehouse către utilizatorii de business.

Pasul 1: setul de date. Din același set sintetic au rezultat două variante: un fișier plat (`legacy_sales_flat.csv`, 20 de coloane, 7,6 MB) și cinci tabele separate: `fact_sales` (43.208 linii), `dim_date`, `dim_product`, `dim_customer` și `dim_store`. Fișierele au fost încărcate în Power BI Desktop prin Get data, cu tipurile de date verificate (chei întregi, sume zecimale, date calendaristice).

Pasul 2: schema stea. Tabelul de fapte este legat de cele patru dimensiuni prin relații unu-la-mulți (1:*), cu filtrare într-un singur sens, dinspre dimensiune spre fapte. `dim_date` a fost marcat ca tabel de date, pentru ca funcțiile de timp să funcționeze corect. Măsurile sunt grupate într-un tabel separat, `_Masuri`.

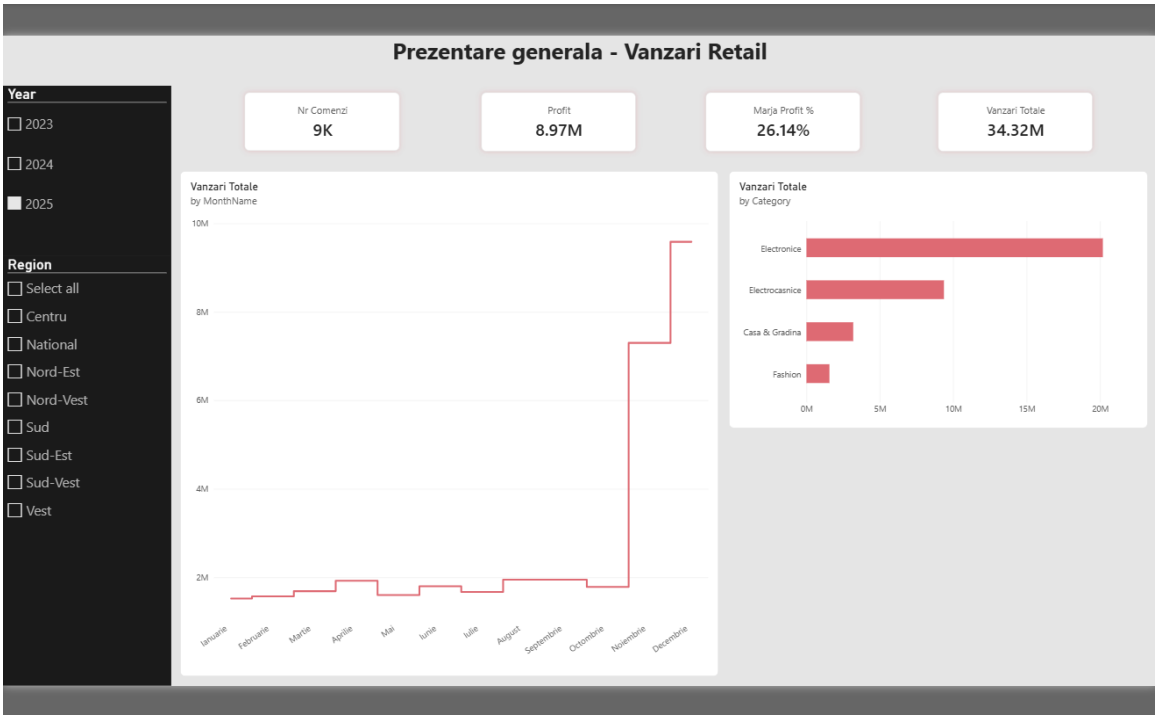


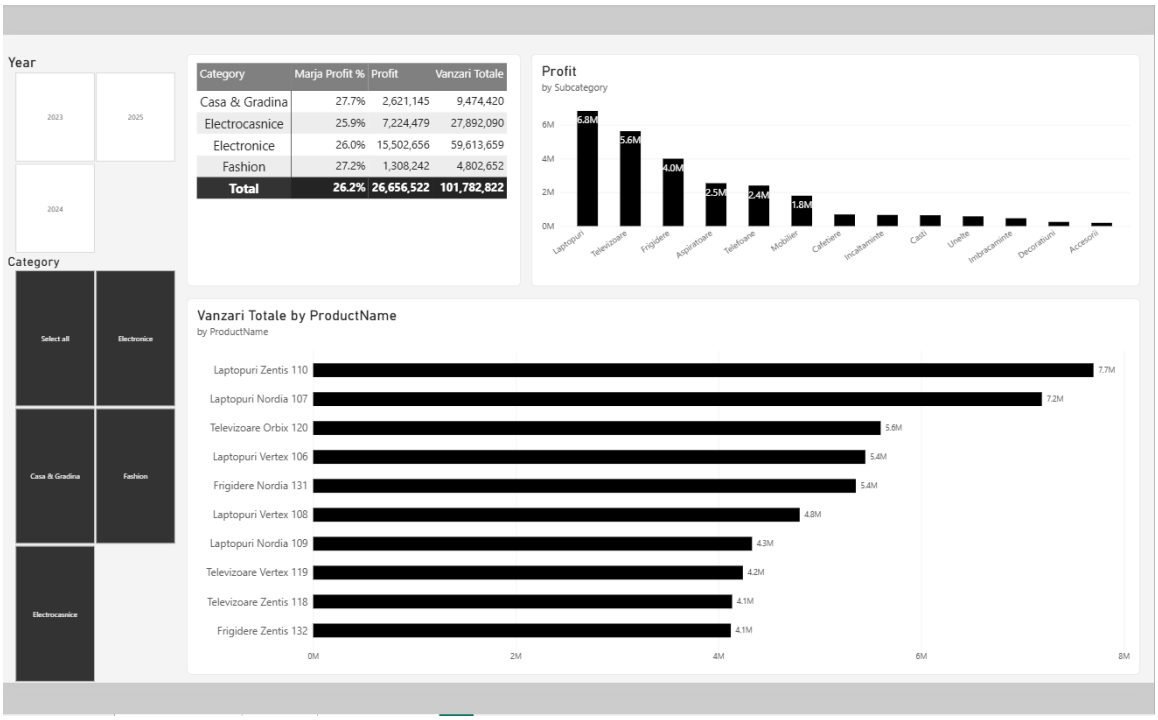
Pasul 3: măsurile DAX. Logica de calcul se definește o singură dată în model și o folosesc toate vizualele:

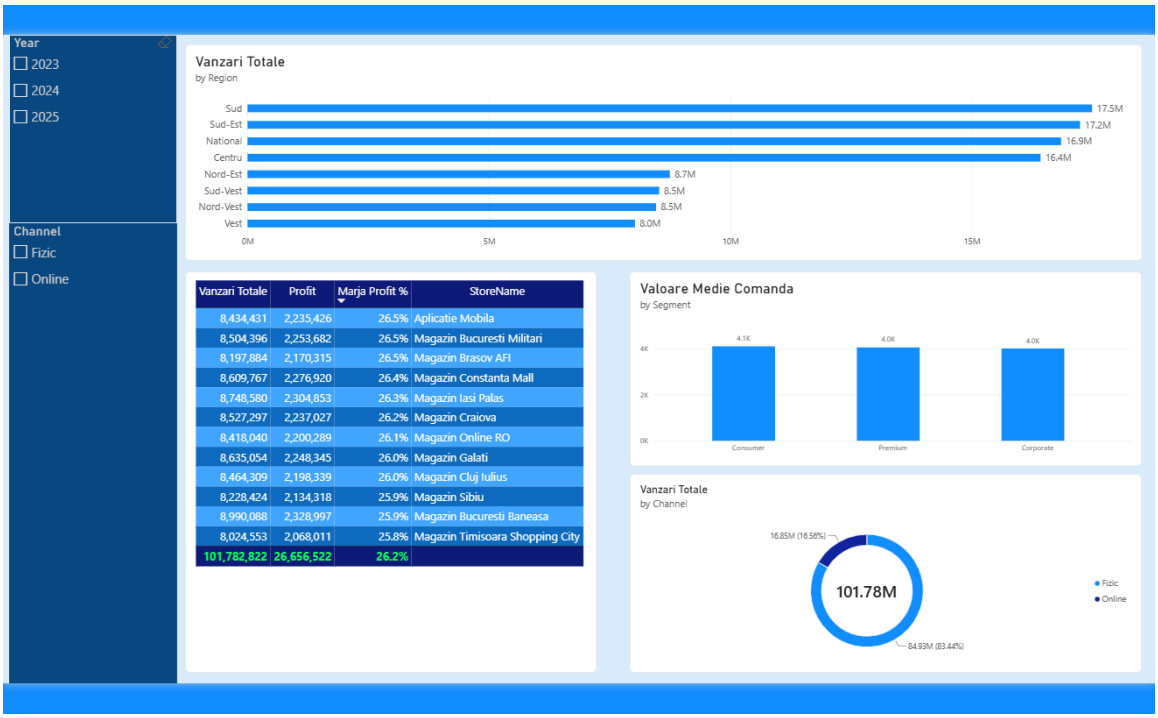
```
Vanzari Totale = SUM(fact_sales[SalesAmount])
Profit = [Vanzari Totale] - SUM(fact_sales[CostAmount])
Marja Profit % = DIVIDE([Profit], [Vanzari Totale])
Nr Comenzi = DISTINCTCOUNT(fact_sales[OrderID])
Valoare Medie Comanda = DIVIDE([Vanzari Totale], [Nr Comenzi])
Vanzari An Anterior = CALCULATE([Vanzari Totale], SAMEPERIODLASTYEAR(dim_date[Date]))
```

Pasul 4: dashboardul. Cele trei pagini răspund la întrebările de business ale unui manager de retail:

1. *Prezentare generală:* cum evoluează vânzările, profitul și marja pe luni, categorii și regiuni.
2. *Produse:* ce se vinde cel mai bine și ce aduce profit.
3. *Clienți și magazine:* ce canal, regiune și magazin contribuie cel mai mult.


Prezentare generala - Vanzari Retail
Year
2023
2024
2025
Region
Select all
Centru
National
Nord-Est
Nord-Vest
Sud
Sud-Est
Sud-Vest
Vest
Nr Comenzi
9K
Profit
8.97M
Marja Profit %
26.14%
Vanzari Totale
34.32M
Vanzari Totale
by MonthName
10M
8M
6M
4M
2M
Ianuarie
Februarie
Martie
Aprilie
Mai
Iunie
Iulie
August
Septembrie
Octombrie
Noiembrie
Decembrie
Vanzari Totale
by Category
Electronice
Electrocasnice
Casa & Gradina
Fashion
0M
5M
10M
15M
20M


Year
2023
2025
2024
Category
Select all
Electronice
Casa & Gradina
Fashion
Electrocasnice
Category | Marja Profit % | Profit | Vanzari Totale
Casa & Gradina | 27.7% | 2,621,145 | 9,474,420
Electrocasnice | 25.9% | 7,224,479 | 27,892,090
Electronice | 26.0% | 15,502,656 | 59,613,659
Fashion | 27.2% | 1,308,242 | 4,802,652
Total | 26.2% | 26,656,522 | 101,782,822
Profit
by Subcategory
6M
4M
2M
0M
6.8M
5.6M
4.0M
2.5M
2.4M
1.8M
Laptopuri
Televizoare
Frigidere
Aspiratoare
Telefoane
Mobilier
Cafetiere
Incalzitoare
Casti
Uneltе
Imbracaminte
Decoratiuni
Accesorii
Vanzari Totale by ProductName
by ProductName
Laptopuri Zentis 110
7.7M
Laptopuri Nordia 107
7.2M
Televizoare Orbix 120
5.6M
Laptopuri Vertex 106
5.4M
Frigidere Nordia 131
5.4M
Laptopuri Vertex 108
4.8M
Laptopuri Nordia 109
4.3M
Televizoare Vertex 119
4.2M
Televizoare Zentis 118
4.1M
Frigidere Zentis 132
4.1M
0M
2M
4M
6M
8M



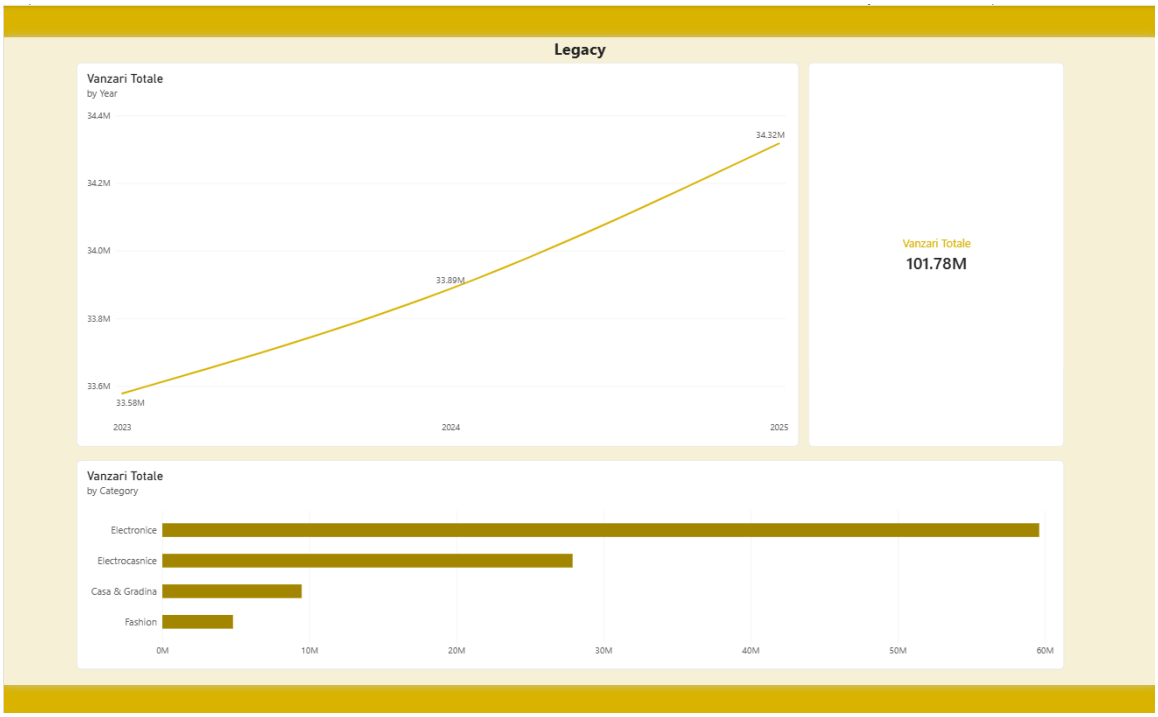
6. Rezultate și interpretare

Modelul stea dă exact aceleași rezultate ca tabelul plat (101,78 milioane în vânzări totale), dar le oferă într-o formă mai ușor de întreținut și de extins; la 43.000 de rânduri, performanța este identică.

Ce arată dashboardul (date sintetice)

- **Concentrare pe categorii:** Electronice aduce 59,6 milioane din 101,8 milioane vânzări (aproximativ 59%) și 15,5 milioane din 26,7 milioane profit. Marjele sunt apropiate între categorii (25,9% la Electrocasnice, 27,7% la Casă și Grădină), deci profitul urmează în principal volumul.
- **Produse:** primele subcategorii la profit sunt Laptopurile (6,8 milioane), Televizoarele (5,6 milioane) și Frigiderele (4,0 milioane).
- **Sezonalitate puternică:** în 2025, vânzările stau la 1,5-2 milioane pe lună până în octombrie, apoi cresc la aproximativ 7,3 milioane în noiembrie și 9,6 milioane în decembrie. Aceste două luni aduc aproape jumătate din vânzările anului. Exact pentru astfel de vârfuri contează scalarea la cerere.
- **Canale:** magazinele fizice generează 83,4% din vânzări (84,9 milioane), iar canalele online 16,6% (16,9 milioane).
- **Creștere moderată:** vânzările anuale sunt 33,58 milioane (2023), 33,89 milioane (2024) și 34,32 milioane (2025), adică aproximativ +0,9% și +1,3%.

Testul legacy vs. stea



Criteriu	Legacy (tabel plat)	Schema stea
Vânzări totale	101,78 milioane	101,78 milioane
Fișiere sursă (CSV)	1 fișier, 7,6 MB	5 fișiere, aproximativ 2,5 MB în total
Fișier Power BI (.pbix)	725 KB	699 KB
Timp interogare DAX (card, bară pe categorie, linie)	4 ms fiecare	4 ms fiecare

Performanța nu diferă la acest volum, iar mărimea fișierului Power BI este aproape aceeași, pentru că Power BI comprimă bine valorile repetate. Testul nu este perfect comparabil: modelul stea a fost măsurat cu filtrul pe anul 2025 și cu zece vizuale pe pagină, iar cel legacy fără filtru și cu trei vizuale. Reîncărcarea datelor nu a fost cronometrată, deoarece la acest volum diferența ar fi imperceptibilă.

Unde apare câștigul real. Diferența se vede în sursele de date: tabelul plat de 7,6 MB repetă numele produsului, clientului și magazinului pe fiecare rând, de aproape trei ori mai mult decât cele cinci tabele separate. În schema stea, un nume de produs se schimbă într-un singur rând, o dimensiune nouă se adaugă fără a reface tabelul de fapte, iar aceleași dimensiuni se reutilizează pentru alte subiecte (stocuri, retururi). Costul unei interogări crește odată cu volumul, așa că avantajul de performanță al unui model bine proiectat devine vizibil abia la milioane de rânduri, volum care nu a fost testat aici.

7. Concluzii

Reproiectarea unui DW clasic într-o arhitectură modernă începe de la model, nu de la tehnologie: schema stea a dat aceleași cifre ca tabelul plat, dar cu o structură mai curată, mai ușor de modificat și de extins.

Concluziile mele

1. **Modelarea contează înaintea platformei.** Un model dimensional bine făcut este stratul gold al oricărui lakehouse; fără el, mutarea în cloud doar mută problema.
2. **La volum mic, câștigul nu este viteza.** Interogările au durat la fel (4 ms), iar fișierele Power BI au avut dimensiuni apropiate. Beneficiul real este în întreținere, în reutilizarea dimensiunilor și în pregătirea pentru creștere.
3. **Sezonalitatea justifică arhitectura modernă.** Aproape jumătate din vânzările anului vin în două luni, iar o capacitate plătită la consum și scalată la cerere se potrivește mai bine decât una dimensionată pentru vârf tot anul.
4. **Arhitectura modernă are un preț.** Cere competențe de cloud și de ingineria datelor, control al costurilor și guvernanță; pentru o firmă mică, cu rapoarte stabile, un DW clasic bine proiectat poate rămâne suficient.

Limite ale studiului. Datele sunt sintetice, iar volumul (43.208 linii) este mic. Prototipul acoperă doar stratul de modelare și raportare, nu ingestia, orchestrarea sau guvernanța dintr-un lakehouse real. Testele de performanță nu sunt perfect comparabile (filtre și număr de vizuale diferite). Un pas următor firesc ar fi repetarea testului pe zeci de milioane de rânduri și implementarea straturilor bronze, silver și gold într-o platformă cloud.

8. Bibliografie

- Armbrust, M., Ghodsi, A., Xin, R., Zaharia, M. (2021). *Lakehouse: A New Generation of Open Platforms that Unify Data Warehousing and Advanced Analytics*. CIDR 2021. vldb.org/cidrdb/2021
- Databricks. *What is the medallion lakehouse architecture?* Documentație oficială. docs.databricks.com
- Inmon, W. H. (2005). *Building the Data Warehouse* (ed. a 4-a). Wiley.
- Kimball, R., Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling* (ed. a 3-a). Wiley.
- Microsoft. *Understand star schema and the importance for Power BI*. Microsoft Learn. learn.microsoft.com

Setul de date folosit în partea practică este sintetic, generat pentru acest studiu de caz.